

AI Agent for Semiconductor and Manufacturing: MAX for Semiconductor


Prof. Joung-ho Kim

TeraByte Interconnection and Package Laboratory
School of Electrical Engineering
KAIST

2026.7.23

Part1: AI Agentic Era


AI Agent란?



< AI agent 소개 >

- 설정된 목표를 달성하기 위해 “스스로” 환경을 인식하고 데이터를 분석하며, “스스로” workflow를 설계 및 수행하여, “스스로” 문제를 해결할 수 있는 AI 시스템.
→ 단순 연산을 넘어 인과관계를 이해하고 사고를 할 수 있음.
- AI agent의 구성 요소
 - 1) Generative AI : LLM이 많이 사용되며, agent의 두뇌 역할을 함.
 - 2) Planning : 목표 달성을 위한 계획을 생성함.
 - 3) Memory : 성능 향상을 위해 단기 및 장기 context를 저장함.
 - 4) Tools : agent가 문제 해결을 위해 활용할 수 있는 SW 또는 DB.

AI Development Trend: The Shift from AI Assistants to AI Agents



< AI Development Trend: The Shift from AI Assistants to AI Agents >

- Open source
- Proactive AI
- Autonomous AI
- Personnel AI
- 20 hours AI
- Access to computer, files, PW, and API
- Telegram
- Local LLM or Cloud LLM
- More token for 24 hours and higher cost
- Local memory
- Long term memory
- Change AI business
- Privacy, safety issues



OpenClaw

THE AI THAT ACTUALLY DOES THINGS.


Clears your inbox, sends emails, manages your calendar, checks you in for flights.

All from WhatsApp, Telegram, or any chat app you already use.

NEW

OpenClaw Partners with VirusTotal for Skill Security →

OpenClaw



챗봇을 넘어선 자율적 문제 해결자: 에이전틱 AI란?


$$\text{Agentic AI} = \text{LLM} \times (\text{Memory} + \text{Tools} + \text{Planning})$$



- **단순 챗봇:** 사용자의 질문에 일회성 텍스트로 대답.
- **에이전틱 AI:** 스스로 계획을 세우고, 외부 도구(웹, 코드, 파일)를 사용해 복잡한 목표를 달성.

미래의 1인 기업: 100대의 Mac Mini와 자율형 AI

단일 창업자가 100인 규모의 생산성을 설계하는 방법론




Part2: TeraLab AI Agents


Frontier Model Comparison Matrix


항목 (Metric)	Kimi K3	Claude Fable 5	GPT-5.6 Sol
Parameter	2.8T MoE	Closed	Closed
Context	1M Tokens	Hundreds of K	Hundreds of K
Modality	Text/Vision/Video Native	Text/Vision	Text/Vision
Openness	Open-Weight	Closed	Closed
Agent Elo	1668	1760	1748

K3는 최고봉 모델 대비 종합 성능은 소폭 열세이나, **프론티어급 개방형(Open-Weight)** 및 **압도적 컨텍스트(1M)**라는 독보적 강점을 지님.

HBM Allocation: LLM은 물리적 메모리를 어떻게 분할하는가?








< 3D Integrated NMC-HBM Architecture above HBM DRAM >


- By integrating a NMC processor die and cache die above HBM, the proposed 3D NMC-HBM achieves high performance and energy efficient computing through dedicated TSV interconnection and power supply network.

Jitters in High speed I/O channels




GPU-HBM-HBF 의 온도 분포


GPU-HBM
(HBF 없는 경우)



GPU-HBM-HBF
(HBF 80W 소모 경우)






GPU-HBM-HBF
(HBF 160W 소모 경우)




5 I: Methodologies

- Signal I Integrity
- Power I Integrity
- Ground I Integrity
- Thermal I Integrity
- Artificial I Intelligence




AI Chip Design Agent for Hardware Design



< AI agent for chip design >

- AI agent for chip design is applicable for ① hardware simulation and design automation, ② logical thinking and reasoning ③ design optimization ④ data analysis.
 - Simulation and design cost ↓
 - Chip performance ↑

Flow of PDN Simulation using ADS-Python with Openclaw



< 오픈클로를 이용한 PDN Simulation >

- 오픈클로 자체적으로 PDN Simulation을 할 수 있는 능력은 없음.
- 따라서, Python으로 ADS Schematic과 시뮬레이션 세팅을 구축하고, .md 파일을 통해 Openclaw로 구동 시키는 방법을 선택.
- Openclaw를 통해, Telegram 채팅으로 ADS를 작동 시키고, 결과를 얻을 수 있음.
- 최종적인 목표는 결과를 보며 알아서 Feedback loop을 형성하는 것.



Random Package Simulation Demo 1: Request

해서

이번엔 그냥 40x40 패키지에, via island가 중앙 10mm by 10mm에 있는 PDN Z를 뽑아볼래?

오후 7:21

이번엔 real package가 아니라 단일 중앙 via island라서 [top-cell-name].png + Z plot 1개로 만들게. 40x40, 중앙 (20,20), via island 10x10로 잡아서 실행할게.

오후 7:21

한 번 실패했어. 구조 생성은 했는데 ADS export 단계에서 에러가 났어. 로그 확인해서 바로 재시도할게.

오후 7:21

단일 via island라 포트가 1개라서 기존 GPU 그룹 스크립트가 Z(2,2)를 찾으면서 한 번 더 걸렸어. Z(1,1) 단일 plot으로 바로 처리할게.

오후 7:22

해서


유닛셀은 5mm 야

오후 7:22

완료했어. 40x40 패키지, 중앙 via island 10x10 mm로 돌렸고 단일 포트라 Z(1,1) PDN plot으로 export했어.

참고: 10x10 island가 4 mm unit-cell grid에 딱 안 맞아서 warning은 있지만, 시뮬레이션/plot 주출은 정상 완료했어.


오후 7:23



User chat



Openclaw chat



맞아, 유닛셀 5 mm로 다시 돌릴게. 그러면 중앙 10x10 island가 grid에 딱 맞아. 이전 4 mm 결과는 무시하고 새로 export할게.

오후 7:23

ADS는 정상 돌았는데 자동 export가 단일 포트인데도 Z(2,2)를 찾는 기본 exporter 때문에 실패했어. dataset에서 Z(1,1)만 추출 export해서 보내줄게.

오후 7:24


simulation 돌려서 figure 하나 얻어줘. 오후 5:10 ✓

어떤 figure를 원하는지 문맥상 첫 번째 SNP의 EQ별 eye opening 비교 그림으로 보고 진행할게. 먼저 기존 스크립트/결과 파일 구조를 다시 확인해서, 필요한 만큼만 시뮬레이션을 돌리고 그림 파일로 뽑겠다.

오후 5:10

실행 환경은 기본 python 쪽에 pandas/matplotlib/scipy가 있어서 그림 쓰면 된다. 방금까지 찾은 best 조건인 첫 번째 SNP + FFE Q5 + CTLE -8dB(index 7)로 단일 시뮬레이션을 돌려서 figure PNG를 저장해볼게.


오후 5:12



시뮬레이션 돌려서 figure 하나 생성했어.


- 조건: 첫 번째 SNP / FFE = Q5 / CTLE = -8dB (CTLE_Index = 7)
- Figure:
work_2/2606_Seasin2p0p102_Datagen/Sim_Result/figure/epp_HJ2606_sample122.png
- 결과: EH_M = 45.7893, EM_M = 0.2486, EH_T = 46.2259, EW_T = 0.2213

[Optimization Agent] Through Thermal Via (TTV) Optimization Agent



< Example of Improvement of TTV Placement Results >

예시: HBM Design Agent의 소자 배치 최적화 및 이유 설명





Q: Optimize HBM's decoupling capacitor placement



A: Okay. Here is the optimized design by using IRL (Interactive reinforcement learning) decap design agent.

상면



Q: Why did you place decap 5 at there?



A: The placement of decap 5 at location (6, 14, 0) is expected to have a substantial impact on reducing self-impedance for Port 4

하면




Q: What if decap 8 was placed at (5,5,0) instead?



A: Based on the information you provided, it seems that it is better to assign Decap 5 at (1,4,1) in terms of self impedance at port 2, but not in terms of the other components.


워크샵은 미시적 반도체 설계부터 거시적 일상까지
3가지 핵심 영역을 다룹니다.



Part3: Agentic AI for MAX in Manufacturing

- 1) Design, Simulation, Optimization
- 2) Supply chain management
- 3) Finance management
- 4) Human resource management
- 5) Autonomous Manufacturing control

반도체 팹: AX 테스트베드로서의 가치 (Why the Semiconductor Fab?)



압도적 데이터 밀도 (High Data Density)

1G 메모리 디바이스 기준 400 Step 이상의 고정밀 공정 수행 (Over 400+ Steps for 1G memory base).

구조화된 기반 (Structured Foundation)

MES, 설비 로그 등 데이터의 표준화 및 구조화가 이미 상당 수준 진행됨.
(High degree of existing digitization).

결론 (Conclusion)

제조 데이터 공동 축적과 도메인 특화 AI 모델을 실증하기 위한 최적의 산업 도메인
(The perfect domain for demonstrating domain-specific AI models and shared data lakes).

전공정과 후공정의 AX 적용 시나리오 (AX in Front-end vs Back-end)


구분 (Division)	전공정 (Front-end)	후공정 (Back-end / Packaging)
주요 공정 (Core Processes)	산화, 포토, 식각, 증착, CMP (Oxide, Photo, Etch, CVD)	패키징, 테스트, TSV, 범프 (Packaging, Test)
AX 최적화 목표 (AX Target)	레시피 튜닝, 공정 윈도우 축소 (Recipe tuning, narrowing process windows)	3D 적층 응력 관리, 테스트 커버리지/비용 트레이드오프 (3D integration stress, Test coverage vs Cost)
대표 AI 적용 (Key AI App)	불량 패턴 조기 탐지 (Anomaly early detection)	설계-조립 조건 통합 최적화 (Co-optimization of design and assembly)

공정 레시피 최적화 솔루션 Alsphere 중심으로 반도체 포함한 스마트 제조 시장의 **Emerging Category**를 선정

- ✓ **LG Display** 공정 제품 공동 개발 및 **SK, Samsung** 제품 평가 진행 중, 대학/연구소 제품 공급 중
- ✓ 정부 공공밥 (나노융합기술원) 스마트화 프로젝트 진행 중 및 확대 계획



Alsphere



반도체 공정 구조 예측 및 레시피 최적화 솔루션
(LG 디스플레이 공동개발, NNFC 사업)

반복 실험 최소화 → 공정 최적화 기간 20% 단축





Alsis



반도체 소자의 전기적 특성 예측 솔루션
(하이닉스, 삼성 등에서 제품 평가)

기존 모델링 툴 대비 정확도 x10, 속도 x100

[종합] 피지컬 AI 생태계 구축을 위한 7계층 성공 스택

L7. 비즈니스/전략		2-5년 내 투자 회수, 수율/인건비 개선, 명확한 KPI 설정.
L6. 운영/조직		지속 가능한 RobOps 프로세스 및 안전/컴플라이언스 내재화.
L5. 응용/도메인		좁고 반복적인 High-ROI 과제(물류, 검사 등)부터 단계적 확장.
L4. 모델 레이어		파운데이션/월드 모델 기반 가상 연계 및 도메인 적용 학습.
L3. 데이터/메모리		표준화된 태깅, 장단기 메모리 분리, Sim2Real 전략.
L2. 컴퓨팅 인프라		ms 단위 지연 달성(Edge), 고가용성 통신, OTA 및 보안.
L1. 물리 인프라 (Basement)		기존 OT(PLC 등)와의 통합, 고품질 센서 배치 및 유지보수 설계.

MAX AI 의 적용

<물류 시설>



<생산공장>



<자율주행자동차>



<전쟁 무기체계>



- 1) 목표가 분명해야 한다
- 2) RoI 를 정의하라
- 3) 데이터 정의, 공급, 확보
- 4) Infra: AI computing: Cloud computing or Local computing
- 5) Token 비용
- 6) 생산성: 인건비 절감, 수율 향상, 생산량 증가
- 7) AI 모델 확보(Open source, local model)
- 8) AI architect 중요 (DNN, Transformer model, reinforcement learning, LLM)
- 9) 운용 인력
- 10) 비용 지출
- 11) Vibe coding 활용
- 12) Test and Evaluation 중요